

Vertical AI & Heavy Document Processes

État des architectures en 2026
et positionnement stratégique de Brexon

RAPPORT D'ÉTUDE

SKEMA

MSc Chef de Projet en IA

Équipe Brexon

Kosseila · Léa · Imad · Axelle · Sami

Partenaire

Brexon — Samir Tony (CEO)

Thématique

L'IA et la surcharge cognitive

Remise

30 juin 2026



Sommaire

1. Introduction

- 1.1 Thématique
- 1.2 Problématique
- 1.3 Contexte et pertinence
- 1.4 Objectifs de l'étude

2. Méthodologie

- 2.1 Organisation de l'équipe
- 2.2 Démarche d'enquête
- 2.3 Place des outils d'IA

3. Analyse et résultats

- 3.1 Tendances de marché
- 3.2 Benchmark et cartographie
- 3.3 Validation des hypothèses

4. Recommandations

- 4.1 Architecture : à intégrer, surveiller, écarter
- 4.2 Expérience utilisateur
- 4.3 Verticaux d'extension
- 4.4 Approche responsable de l'IA

5. Analyse critique : IA et surcharge cognitive

6. Conclusion, limites et apprentissages

- 6.1 Apprentissages clés
- 6.2 Limites de l'étude
- 6.3 Conclusion et perspectives

Annexes

1. Introduction

1.1 Thématique

La généralisation des grands modèles de langage horizontaux (ChatGPT, Claude, Gemini) a déplacé la question centrale : il ne s'agit plus de savoir si l'IA sait produire, mais si elle réduit réellement la charge de l'utilisateur. Le terrain confirme un paradoxe : sans cadrage, l'IA générative élargit le périmètre du travail possible plus qu'elle ne réduit le travail nécessaire — l'utilisateur reformule, compare, explore, et finit par produire davantage tout en ressentant moins de progression. Cette étude interroge donc, à chaque étape, où se loge la surcharge cognitive et si l'IA la réduit, la transforme ou l'amplifie.

1.2 Problématique

Quel est l'état réel des architectures et des briques technologiques du Vertical AI en 2026, comment se positionne Brexon dans ce paysage, et quels autres verticaux présentent des opportunités d'extension pertinentes pour les Heavy Document Processes ?

1.3 Contexte et pertinence

Le Vertical AI s'est imposé en 2026 comme la thèse d'investissement de référence du logiciel d'entreprise : selon Bessemer, il vise les quelque 13 % du PIB consacrés au travail qualifié plutôt que les budgets informatiques¹. Les secteurs à forte intensité documentaire — droit, santé, finance, commande publique, BTP — partagent une même nature : ce sont des Heavy Document Processes, des chaînes documentaires denses, codifiées et traversées de dépendances entre pièces (CCTP, CCAP, DPGF). Brexon, startup française incubée chez SKEMA Entrepreneurs et lauréate de la Bourse French Tech Innovation 2026², adresse en premier la réponse aux appels d'offres publics du BTP — un marché de l'ordre de 89 Md€ par an³ — sur des dossiers de plusieurs centaines de pages, et revendique une posture nette : l'IA n'est qu'une brique parmi d'autres, aux côtés du process, de la base de connaissances et des workflows métier.

1.4 Objectifs de l'étude

L'étude vise à dresser une matrice des briques technologiques observées, à cartographier les éditeurs de Vertical AI et à y situer Brexon, à identifier deux à trois verticaux d'extension prioritaires, et à formuler des recommandations architecturales pour 2026-2027 intégrant une approche responsable de l'IA.

2. Méthodologie

2.1 Organisation de l'équipe

Le travail a été mené par une équipe de cinq personnes aux rôles complémentaires : Axelle (coordination et cadrage), Léa (benchmark et UX), Imad (architecture technique IA), Kosseila (terrain et entretiens) et Sami (captation vidéo). Le cadrage initial et les analyses ont fait l'objet

¹ Bessemer Venture Partners / VC Cafe, « Vertical AI in 2026 », mai 2026 ; Sapphire Ventures, « 2026 Software x AI », mars 2026.

² brexon.fr ; publications LinkedIn de l'équipe Brexon (Microsoft for Startups ; SKEMA Entrepreneurs LAUNCH ; Bourse French Tech Innovation 2026 / Bpifrance).

³ Estimation citée par Brexon (LinkedIn / brexon.fr, 2025-2026) ; ordre de grandeur de la commande publique BTP, non vérifié de façon indépendante.

de restitutions croisées, dans une logique de co-construction entre profils techniques et managériaux.

2.2 Démarche d'enquête

L'approche est hypothético-déductive : recherche documentaire, reformulation du problème, benchmark, puis vérification terrain à VivaTech (17-19 juin 2026). Trois hypothèses falsifiables ont été posées (présentées en section 3.3) puis confrontées aux faits. Les entretiens ont suivi une logique « Mom Test » centrée sur les pratiques et les coûts réels (« comment faites-vous aujourd'hui ? »), jamais sur des intentions d'achat. L'échantillon réalisé comprend cinq entretiens qualifiés : le checkpoint avec Brexon (Samir Tony), Trustflow (conformité), Talan (valorisation de la donnée), Crédit Agricole (agents spécialisés) et Cogiti (automatisation de process). Le benchmark croise ces entretiens, une revue des sources publiques de 2026 et l'observation des solutions présentées sur les stands.

2.3 Place des outils d'IA

Ce rapport est le fruit du travail de l'équipe : la conception de l'étude, la conduite des entretiens sur le salon, le benchmark, l'analyse critique, l'assemblage des schémas, des sources et les recommandations relèvent entièrement de notre travail et de notre jugement. Les outils d'IA n'ont joué qu'un rôle d'appoint, strictement encadré : aide ponctuelle à la mise en forme, à la création visuelle des schémas et à la relecture rédactionnelle, et accélération de la recherche de sources que nous avons ensuite sélectionnées, lues, vérifiées et interprétées nous-mêmes. Aucune analyse, aucune conclusion ni aucune donnée chiffrée n'a été déléguée à l'IA : les chiffres externes ont été retrouvés à la source et attribués en note, et les biais éventuels des outils (lissage stylistique, hallucination, sur-représentation des sources anglophones) ont été neutralisés par notre relecture et le croisement des sources.

3. Analyse et résultats

3.1 Tendances de marché

Quatre tendances structurent le paysage observé.

D'abord, le modèle se commoditise et le process devient l'avantage défendable. Les modèles frontière ont banalisé le raisonnement spécialisé : Harvey, pourtant valorisée 11 Md\$, reconnaît devoir se différencier sur l'orchestration des workflows et l'intégration plutôt que sur la performance du modèle⁴. Le terrain converge : Cogiti situe sa valeur dans sa couche de code propriétaire et non dans le modèle de base, Crédit Agricole souligne que les généralistes n'ont pas les spécificités métier, et Trustflow rappelle que spécialiser une IA, c'est lui fournir contexte et méthode — « cela reste du LLM ».

Ensuite, on passe du RAG simple au post-RAG, mais le coût gouverne. Une part majoritaire des déploiements RAG (de l'ordre de 72 à 80 %) n'atteint pas la production, faute de raisonnement déterministe et de traçabilité⁵. Le GraphRAG est devenu exploitable en production en 2026 pour les requêtes multi-sauts, mais son coût d'extraction atteint trois à

⁴ Sacra, « Harvey revenue, valuation & funding », 2026 ; CNBC, mars 2026.

⁵ FalkorDB, « GraphRAG SDK », avril 2026 (72-80 % des déploiements RAG n'atteignent pas la production).

cinq fois celui du RAG de base ; le RAG hybride reste donc la ligne de base, le graphe n'étant mobilisé que là où la profondeur de raisonnement l'exige⁶.

Par ailleurs, le long contexte n'efface pas la récupération. Les fenêtres de un à deux millions de tokens sont devenues la norme en 2026⁷, mais l'effet « lost in the middle » dégrade la précision de 20 à 50 % sur l'information centrale et le coût croît avec le nombre de tokens : analyser un dossier de 500 pages en une seule passe est possible, mais ni fiable ni économe⁸.

Enfin, souveraineté et conformité deviennent des critères d'achat. L'AI Act devient pleinement applicable le 2 août 2026, avec des obligations de journalisation, de supervision humaine et de transparence des contenus générés ; l'« Omnibus » de mai 2026 a toutefois reporté les obligations relatives aux systèmes à haut risque à fin 2027⁹. Côté infrastructure, la Commission a attribué en avril 2026 un marché de cloud souverain de 180 M€ à des acteurs européens, et l'exposition au CLOUD Act devient un véritable enjeu pour l'achat public¹⁰.

Le tableau ci-dessous synthétise, pour chaque brique, sa maturité, son intérêt pour Brexon, le niveau de risque et un signal à surveiller.

Brique technologique	Maturité	Intérêt	Risque	Signal à 12-18 mois
Long contexte (200K–2M tokens)	Élevée	Élevé	Moyen	Prix en baisse ; fenêtres effectives < annoncées
RAG hybride (vecteur + mots-clés)	Élevée	Élevé	Faible	Standard de production en 2026
GraphRAG / post-RAG	Moyenne	Élevé	Moyen	Clé pour les dépendances ; coût en baisse
Agents (orchestration multi-étapes)	Moyenne	Élevé	Moyen	Montée des agents « long-horizon »
Document AI / IDP	Élevée	Moyen	Faible	Convergence IDP + LLM
Vérificateurs déterministes / règles	Élevée	Élevé	Faible	Exigé par l'AI Act (auditabilité)
Fine-tuning propriétaire	Élevée	Faible	Moyen	Commoditisé : orchestration > fine-tuning
Cloud souverain (Scaleway, OVH)	Moyenne	Élevé	Moyen	Marché UE ; écart de capacité GPU
Traçabilité / observabilité	Moyenne	Élevé	Faible	Échéance réglementaire 2 août 2026

Lecture : intérêt et risque évalués du point de vue de Brexon ; synthèse de l'équipe à partir des sources de la section 3.1.

3.2 Benchmark et cartographie

Le benchmark croise des concurrents directs, des analogues hors secteur et les acteurs émergents du BTP français.

Acteur	Type	Réponse au problème	Forces	Limites
Outils IA appels d'offres BTP (Breek, Tenderbolt, Cypher IA)	Direct	Lecture du DCE, génération du mémoire technique, veille	Spécialisation BTP, base de connaissances, ROI rapide	Cadrage UX variable, pré-décision partielle

⁶ programming-helper.com et NStarX, 2026 (GraphRAG exploitable en production ; surcoût d'extraction d'environ 3 à 5 fois ; le RAG hybride reste la base).

⁷ Morph, « LLM Context Window Comparison », juin 2026 (fenêtres de 1 à 2 millions de tokens devenues la norme).

⁸ Zylos Research et pristren.com, 2026 (effet « lost in the middle » : 20 à 50 % de précision perdue sur l'information centrale).

⁹ Commission européenne (digital-strategy.ec.europa.eu) ; Latham & Watkins, mai 2026 (application au 2 août 2026 ; report du haut-risque à fin 2027).

¹⁰ tech-insider.org, « Cloud souverain UE 180 M€ », avril 2026 (OVHcloud, Scaleway, etc.).

Acteur	Type	Réponse au problème	Forces	Limites
Doctrine (LegalTech)	Analogue vertical	Recherche et analyse juridique via un graphe	Profondeur métier, graphe de dépendances, traçabilité	Vertical unique, pas de chaîne multi-pièces type DCE
Harvey AI (LegalTech)	Analogue vertical	Agents bout-en-bout multi-modèles pour le droit	Orchestration, intégrations, forte échelle	Coût élevé, UX experte, contexte US/UK
Tungsten / Kofax (IDP)	Analogue	Extraction documentaire industrielle multi-secteur	Maturité, intégrations ERP, robustesse	Capture héritée, déploiement long, faible cadrage
Notion AI / Airtable AI	Analogue	Organisation de l'information et IA générative	UX très cadrée, adoption massive	Générique, aucune profondeur réglementaire
Cogiti	Direct (terrain)	Automatisation de process en marque blanche	UX « zéro superflu », portabilité de la donnée	Dépend d'une co-construction client

Sources : sites éditeurs et presse spécialisée 2026 (section 3.1, annexe A) et entretiens terrain (annexe C).




Figure 1 — Cartographie 2x2 du Vertical AI (cadrage UX × profondeur process). Le quadrant supérieur droit constitue le white space visé par Brexon.

Le paysage se répartit en quatre familles. Les LLM généralistes et les SaaS larges comme Notion AI offrent un bon cadrage mais aucune profondeur réglementaire ; les plateformes d'IDP industrielles comme Tungsten et les LegalTech profondes comme Doctrine ou Harvey maîtrisent le process mais exposent une interface complexe ou un vertical unique. Le quadrant « fort cadrage et haute profondeur » est peu peuplé : c'est l'espace visé par Brexon. Cet espace est réel mais contestable, car Cogiti et les outils français de réponse aux appels d'offres BTP y progressent. La défense de Brexon repose sur le cumul de trois leviers : la profondeur du process, la pré-décision logicielle et la traçabilité.

3.3 Validation des hypothèses

H1 : les éditeurs ont des architectures hétérogènes, certains maîtrisant réellement le process, d'autres rebrandant un RAG générique → est **validée** : la commoditisation du modèle, la condamnation annoncée des « thin wrappers » et trois entretiens convergents le confirment¹¹.

H2 : les architectures post-RAG seraient indispensables en production pour gérer les dépendances du DCE → est **nuancée** : le GraphRAG est validé pour le raisonnement multi-sauts mais reste coûteux, et la production repose en pratique sur une architecture hybride (long contexte, graphe ciblé, vérificateurs déterministes) plutôt que sur du GraphRAG pur.

H3 : les acheteurs privilégient la traçabilité à la créativité textuelle → est **validée** : les exigences de l'AI Act, les pratiques de gouvernance évoquées en entretien (Trustflow, Crédit Agricole, Talan) et le poids croissant du cloud souverain le confirment.

4. Recommandations

4.1 Architecture : à intégrer, surveiller, écarter

Nous recommandons d'intégrer une architecture hybride combinant le long contexte (pour la compréhension d'une pièce), un GraphRAG ciblé sur les dépendances entre pièces (CCTP, DPGF, planning) et des vérificateurs déterministes pour les règles non négociables ; une couche de traçabilité conforme à l'AI Act dès maintenant (journalisation, points de supervision humaine, étiquetage des sorties), avant l'échéance du 2 août 2026 ; une gouvernance du coût par dossier en complément du routeur multi-modèles existant ; et un hébergement souverain (Scaleway, OVH) assorti d'une clause de non-rétention avec les fournisseurs de modèles. Le schéma ci-dessous résume cette architecture cible.

Architecture cible (hybride) pour la réponse aux appels d'offres




Figure 2 — Architecture cible (hybride) : du DCE au dossier conforme, avec un human-in-the-loop ciblé et des fondations de traçabilité et de souveraineté.

Trois points sont à surveiller : la courbe de coût du GraphRAG et la baisse du prix du long contexte, qui pourraient simplifier l'architecture ; l'écart de capacité GPU souveraine et la

¹¹ VC Cafe, « Vertical AI in 2026: the good, the bad and the ugly », mai 2026.

dépendance d'approvisionnement ; la remontée des concurrents BTP français et l'adoption finale de l'Omnibus. Trois choix sont à écarter : la « passe unique » en long contexte comme seule architecture ; l'autonomie totale sans supervision humaine ; et le fine-tuning propriétaire comme avantage défendable, désormais commodité.

4.2 Expérience utilisateur

La logique de pré-décision de Brexon est pertinente et doit être systématisée : fermer les options sans valeur ajoutée, ne solliciter l'utilisateur qu'aux quatre points à forte valeur (décision de répondre ou non, validation de section, chiffrage, signature), mesurer le travail supprimé plutôt que le temps passé, et rendre visible l'étiquetage des sorties générées afin de préserver l'auditabilité.

4.3 Verticaux d'extension

Trois pistes ressortent, selon une grille « niche, codifié, dépendances entre documents, supervision humaine requise ». En priorité, la réponse aux appels d'offres et marchés privés réglementés (énergie, santé, défense, ferroviaire), adjacence directe à la chaîne existante. Ensuite, la conformité et l'audit réglementaire, portés par l'AI Act et confirmés par l'entretien Trustflow. Puis les demandes de subventions et de financements publics (crédit d'impôt recherche, Bpifrance, fonds européens), dossiers normés à retour sur investissement mesurable. L'assurance (gestion des sinistres) constitue une piste de veille, et l'export francophone (Algérie, Maroc, Égypte) déjà engagé par Brexon offre un axe géographique complémentaire.

4.4 Approche responsable de l'IA

Plusieurs enjeux doivent être traités explicitement. Sur les biais, le risque est de reproduire des schémas de dossiers perdants ou d'entériner des exclusions passées ; il appelle un suivi des biais, une validation humaine et des jeux d'entraînement diversifiés. Sur les compétences, la sur-délégation peut éroder l'expertise interne, ce que limitent une supervision humaine ciblée et la formation. Sur la responsabilité, la signature humaine constitue l'ancrage face à un dossier non conforme. Sur l'emploi, la posture retenue est l'augmentation et la réallocation des équipes vers la stratégie et le chiffrage. Sur l'efficacité et l'environnement, toute hausse de ressources (tokens, latence, coût) doit être justifiée par un gain de qualité documenté, le cloud souverain bas-carbone offrant un angle ESG. Sur la souveraineté enfin, l'isolation des données par client, l'hébergement européen et la non-rétention protègent la propriété des données.

5. Analyse critique : IA et surcharge cognitive

Où se loge la surcharge, et l'IA la réduit-elle, la transforme-t-elle ou l'amplifie-t-elle ? Le terrain dégage trois régimes, synthétisés dans le schéma ci-dessous.

L'IA face à la surcharge cognitive : trois régimes, une résolution




Figure 3 — L'IA face à la surcharge cognitive : trois régimes (réduire, transformer, amplifier) et une résolution par la relocalisation de la charge.

L'IA réduit la charge lorsqu'elle pré-décide et supprime les arbitrages sans valeur — Cogiti revendique d'ailleurs « zéro gadget », sans chatbot superflu. Elle transforme la charge en déplaçant l'effort de la lecture et de la rédaction vers la vérification et la validation : contrôler les sorties devient une tâche cognitive nouvelle, nette positive si la vérification coûte moins que la production, mais nette négative si le taux d'erreur est élevé. Elle amplifie enfin la charge par la surabondance d'options (les SaaS « laissent trop de réglages », selon l'entretien Brexon), par la complaisance d'automatisation et par les échecs silencieux du long contexte, qui exigent davantage de vigilance.

La résolution n'est donc pas l'élimination de la charge mais sa relocalisation : concentrer l'intervention humaine sur les décisions à forte valeur, en l'adossant à une traçabilité complète permettant d'auditer à la demande. Le verdict du terrain confirme la thèse du brief : l'IA verticale qui gagne supprime des options plutôt qu'elle n'en ajoute — à condition de préserver l'auditabilité.

6. Conclusion, limites et apprentissages

6.1 Apprentissages clés

Trois enseignements ressortent. L'avantage défendable a migré du modèle vers le process : la défensibilité se joue sur la profondeur métier et le cadrage, non sur le modèle. Une démonstration de salon n'est pas un système en production : le post-RAG impressionne en démonstration, mais la production est hybride et gouvernée par le coût. Enfin, la conformité est devenue un critère d'achat amont, et non une contrainte aval.

6.2 Limites de l'étude

L'échantillon se limite à cinq entretiens, contre une cible de quinze à vingt-cinq, sur un seul salon et par convenance ; les propos de fondateurs comportent un biais de démonstration ; l'architecture de Brexon est inférée, faute d'accès au code ; certaines données sont des estimations d'équipe ou des éléments marketing non vérifiés de façon indépendante ; l'étude se concentre sur le marché français.

6.3 Conclusion et perspectives

Brexon occupe un espace réel mais contesté, dont la défense tient à la profondeur du process, à la pré-décision et à la traçabilité, et non à la pile technique. Les prochaines étapes consistent à approfondir huit à douze entretiens supplémentaires, à prototyper la brique GraphRAG ciblée sur un dossier réel, et à cadrer le premier vertical d'extension. En 2026, l'IA verticale qui gagne n'est pas celle qui offre le plus d'options, mais celle qui en supprime le plus.

Annexes

Annexe A — Sources

- Thèse Vertical AI 2026 : Bessemer / VC Cafe, « Vertical AI in 2026 », mai 2026 ; Sapphire Ventures, « 2026 Software x AI », mars 2026.
- Harvey AI : CNBC et Sacra, « Harvey at \$11B / \$190M ARR », mars 2026.
- Doctrine : doctrine.fr (fonctionnalités, 2026) ; zevra.tech, « Legaltech 2026 ».
- Tungsten / Kofax : idp-software.com ; IDC MarketScape et Gartner (IDP), 2025-2026.
- GraphRAG et RAG en production : FalkorDB et NStarX, 2026 ; Microsoft GraphRAG.
- Long contexte : Morph et webscraft, juin 2026 ; « Lost in the Middle » (TACL).
- AI Act et Omnibus : Commission européenne (digital-strategy) ; Latham & Watkins, mai 2026.
- Cloud souverain UE et Mistral : tech-insider.org (avril 2026) ; Introl (mars 2026).
- Outils IA appels d'offres BTP : breek.ai ; tenderbolt.ai ; cypher-ia.com.
- Brexon : brexon.fr ; publications LinkedIn de l'équipe (Microsoft for Startups, SKEMA Entrepreneurs, French Tech Innovation 2026).

Annexe B — Place des outils d'IA (rôle d'appoint)

Le contenu intellectuel de ce rapport — problématisation, méthodologie, conduite et analyse des entretiens, benchmark, recommandations et conclusions — a été produit par l'équipe. Les outils d'IA ont été mobilisés de façon marginale et encadrée, sans se substituer à notre jugement :

- Assistants génératifs (Claude, ChatGPT) : aide ponctuelle à la mise en forme et à la relecture rédactionnelle ; aucune analyse ni conclusion déléguée.
- Recherche web : accélération de la collecte de sources, que nous avons sélectionnées, lues, vérifiées et citées nous-mêmes.
- Tableur : mise en forme de tableaux conçus par l'équipe.

Justification : gain de temps sur des tâches non substantielles. Biais identifiés et neutralisés par nos soins : lissage stylistique, risque d'hallucination (relecture systématique), sur-représentation des sources anglophones (croisement avec des sources francophones et primaires). En somme, l'IA a servi d'outil d'appoint ; l'expertise, les choix d'analyse et les conclusions sont les nôtres.

Annexe C — Comptes rendus d'entretien (VivaTech, 17-19 juin 2026)

Les cinq entretiens conduits sur le salon sont restitués ci-dessous, reformulés pour la clarté et présentés selon une trame commune : contexte, points clés, verbatim et apport pour l'étude.

1. Brexon — checkpoint (Samir Tony, CEO)

Contexte. Éditeur SaaS Vertical AI dédié à la réponse aux appels d'offres publics du BTP. Entretien de cadrage avec le porteur sur les angles d'investigation attendus.

Points clés.

- Attente d'un regard neuf : Brexon souhaite être surpris et que l'étude révèle des usages ou des angles non encore captés ; si l'équipe identifie des pratiques déjà employées par Brexon, cela confirme la pertinence de sa direction.
- Marge technique et UX : sur de nombreux SaaS, la mise en place de l'IA s'accompagne d'une multiplication des réglages laissés à l'utilisateur. Brexon veut mesurer à quel point les éditeurs le font

ou non, et cherche au contraire à limiter cette multiplication, qui fragmente le temps passé sur les tâches.

- Décharge mentale : second axe central, la qualité de l'interface pour décharger mentalement l'utilisateur métier.
- Préférence européenne et conformité : intérêt pour des modèles européens et pour le respect de la réglementation IA ; Brexon suit la réglementation européenne, qui englobe la française, tant sur la technique que sur le logiciel.
- Réglementation du BTP : essentiellement française mais proche des standards européens ; la France est parfois plus exigeante, mais l'ensemble reste aligné.
- Ouverture internationale : Brexon est en phase de test en Algérie et au Maroc et explore l'Égypte — d'abord des pays francophones en seconde langue, avant d'envisager la Belgique ou l'Italie.
- Extension produit : l'architecture permet d'adresser d'autres verticaux. Au-delà du BTP, Brexon commence à explorer une nouvelle verticale liée à des demandes réglementaires : partout où l'utilisateur croule sous des documents hétérogènes (formats changeants, pièces scannées), la plateforme peut alléger la charge et améliorer la qualité des réponses — d'où la notion de Heavy Document Processes.

Verbatim. « On essaie de limiter au maximum cette multiplication d'options : est-ce que tu peux y toucher, parce qu'on essaie de faire le mieux pour toi ? »

Apport pour l'étude. Éclaire le positionnement (pré-décision et décharge cognitive) et la stratégie d'extension (verticaux et export) ; informe l'hypothèse H1 et le cadrage de l'étude.

2. Trustflow — conformité réglementaire

Contexte. Éditeur d'une solution d'aide à la conformité (compliance) reposant sur des agents IA.

Points clés.

- Spécialisation contre généralisation : les LLM sont des briques présentes partout ; spécialiser, c'est les rendre « moins généralistes » en leur fournissant des instructions claires, un contexte plus poussé et une méthodologie de travail — la technologie reste un LLM.
- La conformité comme gestion des risques : l'outil aide les clients à se mettre en conformité, ce qui revient essentiellement à gérer des risques.
- Risques propres à l'IA : au-delà des risques classiques (fuites de données, décisions automatiques sans garde-fous humains), des risques spécifiques comme l'empoisonnement des données, c'est-à-dire l'ingestion de données confidentielles ensuite restituées.
- Gouvernance du déploiement : des grilles d'analyse permettent d'examiner des dossiers complets et de décider si un agent IA peut être déployé en toute sécurité ; l'outil assiste la revue réglementaire plutôt que de remplacer le jugement humain.

Verbatim. « Spécialiser une IA, c'est lui donner des instructions plus claires, un contexte plus poussé et une méthodologie ; cela reste du LLM. »

Apport pour l'étude. Confirme H1 (la valeur est dans le contexte et la méthode, pas dans le modèle) et H3 (gouvernance et traçabilité) ; appuie la piste du vertical « conformité ».

3. Talan — valorisation de la donnée

Contexte. Société de conseil et d'ingénierie accompagnant les entreprises de la donnée brute aux outils décisionnels intégrant l'IA.

Points clés.

- Valorisation de la donnée : construction et consolidation de données via des architectures capables de traiter de larges volumes, débouchant sur des outils décisionnels (applications, reporting, briques prêtes à l'emploi).
- Approche sur-mesure : pas de solution unique « sur étagère » ; le choix de la meilleure technologie dépend du contexte client, avec des questions cruciales de RGPD, de confidentialité et d'indépendance vis-à-vis des éditeurs tiers.

- Internalisation ou recours à un tiers : arbitrage entre internaliser les ressources et faire appel à un prestataire pour des capacités plus larges, avec des garde-fous pour sécuriser les données.
- Preuve de valeur : approche pragmatique par « photos avant / après » l'intégration de l'IA ; sur de gros volumes la mesure est difficile, d'où l'isolement de tâches plus petites ou de sessions dédiées comparant les performances avec et sans la solution.

Verbatim. « *Nous faisons des photos avant / après et nous isolons des tâches plus petites pour comparer les performances.* »

Apport pour l'étude. Éclaire la mesure du retour sur investissement et les garde-fous de sécurité et de souveraineté ; renforce H3.

4. Crédit Agricole — agents spécialisés

Contexte. Échange sur l'avantage des agents IA spécialisés face aux assistants généralistes dans un environnement réglementé.

Points clés.

- Limite des généralistes : les assistants généralistes n'ont pas un accès suffisant au niveau de détail requis ; même les modèles récents ne disposent pas des éléments spécifiques à chaque métier.
- Demande orientée tâche : le marché s'oriente vers des agents capables de réaliser une tâche précise, intégrant les spécificités et la réglementation, plutôt que vers des usages vagues.
- Automatisation et responsabilité : l'agent peut décider automatiquement lorsqu'une réponse existe déjà ; à défaut se pose la question de la responsabilité et de l'intervention humaine.
- Conformité intégrée : avantage clé, l'intégration de la réglementation garantit des réponses et des actions conformes.

Verbatim. « *Les modèles généraux n'ont pas les éléments spécifiques propres à chaque métier.* »

Apport pour l'étude. Confirme H1 (profondeur métier) et H3 (conformité et supervision humaine).

5. Cogiti — automatisation de process

Contexte. Solution d'automatisation des process métiers, déployée exclusivement en marque blanche, sur plusieurs verticaux (assurance, logistique...).

Points clés.

- Positionnement : automatisation et optimisation des process opérationnels ; contrairement aux LegalTech très verticalisées sur le documentaire, Cogiti optimise l'ensemble des tâches manuelles des collaborateurs, avec une interface entièrement personnalisée à la charte du client.
- Cas d'usage : repérage d'anomalies (en logistique, erreurs de facturation, écarts et erreurs de paiement) pour faire gagner du temps aux équipes.
- Technique et souveraineté : agnosticisme des modèles — la valeur réside dans la couche de code propriétaire ; portabilité de la donnée, que Cogiti maîtrise, facilitant un changement de modèle ; partenariat de sécurité avec OpenAI pour la confidentialité et l'étanchéité des données.
- UX « zéro superflu » : efficacité brute sur le terrain, sans gadgets ni chatbot génératif classique ; tout est intégré et orienté vers la performance de la tâche.
- Appels d'offres : sujet complexe traité par une méthodologie axée sur la donnée (récupération d'un maximum d'historique et de contexte client) et un entraînement sectoriel, nécessitant une co-construction obligatoire avec le client.

Verbatim. « *La valeur n'est pas dans le modèle de base, mais dans la couche de code propriétaire que nous développons par-dessus.* »

Apport pour l'étude. Confirme H1 (l'avantage défendable réside dans le process et le code) et illustre la pré-décision UX ; concurrent terrain proche de Brexon.